

A8-Series de tiempo

Eliezer Cavazos


2024-11-12

```
ventas = c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
x= ts(ventas, frequency = 4, start=c(2016,1))
tiempo = 1:16
```

Realiza el análisis de tendencia y estacionalidad:

Identifica si es una serie estacionaria

```
plot(tiempo, ventas, col = "red", type = "o", lwd = 2, pch = 19)
```




Grafica la serie para verificar su tendencia y estacionalidad

Analiza su gráfico de autocorrelación

```
ventas_st = ts(ventas, start = tiempo, frequency = 1)
acf(x, col='red', main='AutoCorrelacion')
```


AutoCorrelacion



Identifica si el modelo puede ser sumativo o multiplicativo (puedes probar con ambos para ver con cuál es mejor el modelo)

```
T = decompose(x, type = "m") #para una serie multiplicativa añade: type="m"  
plot(T, col = "blue")
```

Decomposition of multiplicative time series



Calcula los índices estacionales y grafica la serie desestacionalizada

`T$seasonal`

```
##          Qtr1      Qtr2      Qtr3      Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179
```

Analiza el modelo lineal de la tendencia


Realiza la regresión lineal de la tendencia (ventas desestacionalizadas vs tiempo)

```
ventas_desestacionalizadas = (T$x)/(T$seasonal)
x3 = 1:16
y3 = ventas_desestacionalizadas
N3 = lm(y3~x3)
N3

##
## Call:
## lm(formula = y3 ~ x3)
##
```

```
## Coefficients:
## (Intercept)          x3
##      5.1080      0.1474

plot(x3, y3, type = "l")
abline(N3, col = "red")
text(6, 7, "ventas = 5.1080 + 0.1474 trimestre")
```



Analiza la significancia del modelo lineal, global e individual

```
summary(N3)
```

```
##
## Call:
## lm(formula = y3 ~ x3)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## x3           0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
```

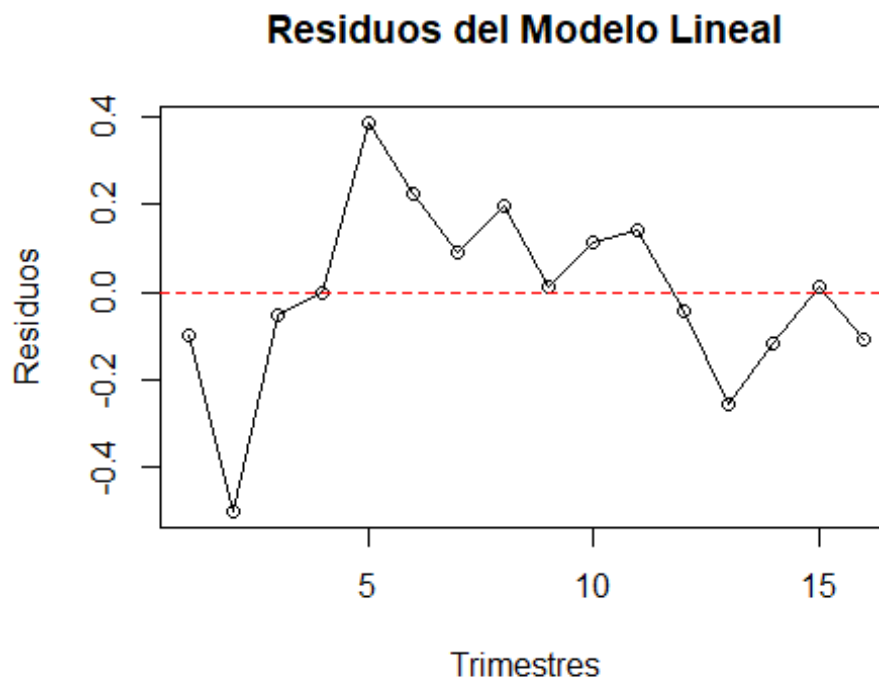
```
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151  
## F-statistic: 162.7 on 1 and 14 DF,  p-value: 4.248e-09
```

Viendo el valor P es muy pequeño menor a 0.05 así que la variable x_3 no es significativa a y_3 , además el valor T es mayor en la intercepción que en el valor de la variable x_3

Haz el análisis de residuos

Calcula el CME y el EPAM de la predicción de la serie de tiempo

```
residuos <- residuals(N3)  
plot(residuos, main="Residuos del Modelo Lineal", ylab="Residuos",  
      xlab="Trimestres", type="o")  
abline(h=0, col="red", lty=2)
```



```
CME <- mean(residuos^2)  
EPAM <- sqrt(CME)  
CME; EPAM  
  
## [1] 0.0397064  
## [1] 0.1992647
```

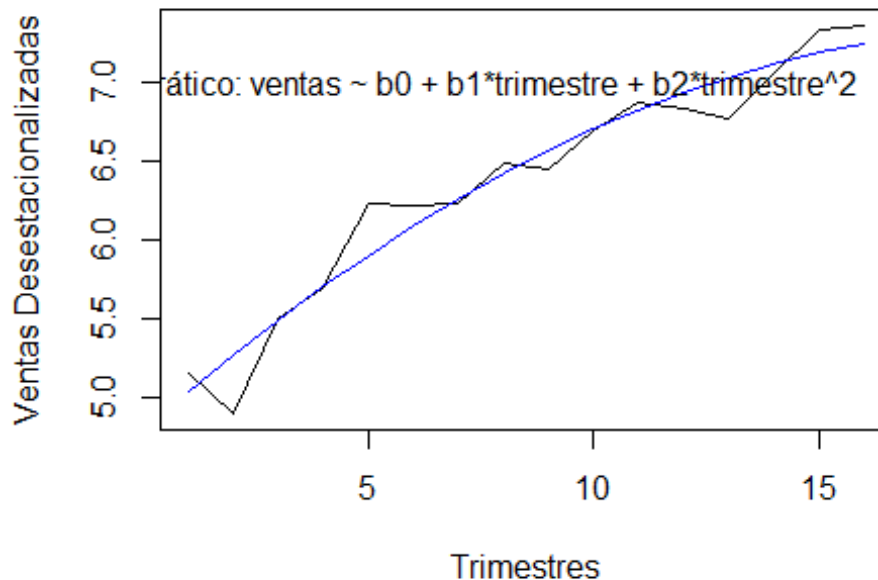
Explora un mejor modelo, por ejemplo un modelo cuadrático: $y =$ Para ello transforma la variable ventas (recuerda que la regresión no lineal es una regresión lineal con una transformación).

```
x3_sq <- x3^2
N4 <- lm(y3 ~ x3 + x3_sq)
summary(N4) # Análisis de la significancia del modelo cuadrático

##
## Call:
## lm(formula = y3 ~ x3 + x3_sq)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.36986 -0.07058 -0.00100  0.11345  0.33110
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.790283   0.152429  31.426 1.20e-13 ***
## x3           0.253302   0.041269   6.138 3.56e-05 ***
## x3_sq        -0.006231   0.002360  -2.640  0.0204 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1784 on 13 degrees of freedom
## Multiple R-squared:  0.9484, Adjusted R-squared:  0.9405
## F-statistic: 119.6 on 2 and 13 DF, p-value: 4.268e-09

plot(x3, y3, type = "l", main="Modelo Cuadrático de la Tendencia",
xlab="Trimestres", ylab="Ventas Desestacionalizadas")
lines(x3, predict(N4), col = "blue")
text(6, 7, "Modelo Cuadrático: ventas ~ b0 + b1*trimestre + b2*trimestre^2")
```

Modelo Cuadrático de la Tendencia



#Concluye sobre el mejor modelo

El valor P de ambos modelos es muy bajo, pero el valor R del segundo modelo es mayor al primer modelo eso significa que el segundo modelo explica mejor la variabilidad de y3 además que el Residual Standard error es menor en el segundo modelo, con esto me puedo dar una idea que el modelo 2 es mejor, también si contamos el valor p de la variable x3_sq podemos ver que esta más cerca de 0.05.

#Realiza el pronóstico para el siguiente año y grafícalo junto con los pronósticos previos y los datos originales.

```
nuevos_trimestres <- 17:20
prediccion_cuadratica <- predict(N4, newdata = data.frame(x3 =
nuevos_trimestres, x3_sq = nuevos_trimestres^2))
ventas_pronosticadas <- prediccion_cuadratica * T$seasonal[1:4] # Ajuste
estacional
plot(1:20, c(ventas, ventas_pronosticadas), type = "o", col = "purple",
xlab="Trimestres", ylab="Ventas", main="Pronóstico de Ventas")
lines(1:16, ventas, col = "black", type="o")
legend("topleft", legend=c("Datos Originales", "Pronóstico"), col=c("black",
"purple"), lty=1)
```

Pronóstico de Ventas

